



CNN 기반 당뇨병성 망막병증 특징 추출 및 심각도 등급 분류

CNN based Diabetic Retinopathy Feature Extraction and Grade Classification

저자 (Authors)	정영훈, 조경진, 김대원 Younghoon Jung, Kyungjin Cho, Daewon Kim
출처 (Source)	전자공학회논문지 56(11) , 2019.11, 61-73(13 pages) Journal of the Institute of Electronics and Information Engineers 56(11) , 2019.11, 61-73(13 pages)
발행처 (Publisher)	대한전자공학회 The Institute of Electronics and Information Engineers
URL	http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE09296320
APA Style	정영훈, 조경진, 김대원 (2019). CNN 기반 당뇨병성 망막병증 특징 추출 및 심각도 등급 분류. 전자공학회논문지, 56(11), 61-73
이용정보 (Accessed)	121.66.139.*** 2021/10/14 15:10 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

논문 2019-56-11-8

CNN 기반 당뇨병성 망막병증 특징 추출 및 심각도 등급 분류

(CNN based Diabetic Retinopathy Feature Extraction and Grade Classification)

정 영 훈*, 조 경 진**, 김 대 원***

(Younghoon Jung, Kyungjin Cho, and Daewon Kim[©])

요 약

비증식성 당뇨병성 망막 병증은 당뇨병 환자의 대표적인 합병증으로서 시력저하와 실명을 일으키는 주요한 원인 중 하나로 알려져 있다. 당뇨병성 망막 병증을 자동으로 탐지하는 연구는 지속적으로 이루어지고 있으나, 여기에 추가적으로 심각도의 등급을 자동으로 분류하는 시스템에 대한 연구의 필요성 또한 대두되고 있다. 본 논문에서는 당뇨병성 망막 병증의 병리적 특징인 미세혈관류, 망막 출혈과 경성 삼출물을 검출하기 위해 Faster R-CNN 기술을 적용하여 해당 병리 증상에 대해 자동으로 검출하는 시스템을 제안하였다. 검출된 특징에 대해 히스토그램 평활화 등의 전처리 과정을 수행하였고, 이 데이터를 이용해 랜덤포레스트 분류기를 학습하고 테스트함으로써 병리증상의 특징을 기반으로 한 심각도 등급을 자동 분류하는 시스템을 고안하였다. 이를 통해 검사자의 주관적 해석 개입을 방지하고 객관적 자료와 지표를 이용하여 구체적으로 판단할 수 있도록 하고 의료 영상 분석 분야 업무의 효율성을 높일 수 있도록 하였다. 본 논문에서 제안하는 방법을 이용해 테스트 안저 영상 103장에 대하여 등급 별 분류 실험을 한 결과 98%의 정확도를 보이는 분류 시스템을 구현할 수 있었고, 이는 향후 다수의 의미 있는 데이터가 수집된다면 더 높은 완성도를 보일 수 있을 것으로 예상된다.

Abstract

Non-proliferative diabetic retinopathy is a representative complication of diabetic patients and is known to be a major cause of impaired vision and blindness. There has been ongoing research on automatic detection of diabetic retinopathy; however, there is also a growing need for research on an automatic severity classification system. This study proposes an automatic detection system for pathological symptoms of diabetic retinopathy such as microaneurysm, retinal hemorrhage, and hard exudate by applying the Faster R-CNN technique. An automatic severity classification system based on the features of pathological symptoms of diabetic retinopathy was devised by training and testing a random forest classifier based on the data obtained through preprocessing, such as histogram smoothing of the detected features. The proposed system enables accurate judgment using objective data and indices while avoiding the subjective interpretation of testers and improving the efficiency of medical image analysis. An experiment of classifying 103 test fundus images with the proposed classification system showed 98% accuracy. The proposed automatic severity classification is expected to show a higher degree of accuracy if a greater amount of meaningful data can be collected in the future.

Keywords : 비증식성 당뇨병성 망막병증, Faster R-CNN, Random Forest, Classification, 의료 영상처리

* 학생회원, M.S. Candidate, Graduate School of Computer Science, Dankook University, Juk-Jeon-Ro 152, Yong-In-Si, Kyung-Ki-Do, 16890.

** 비회원, Department of Ophthalmology, College of Medicine, Dankook University, Dan-Dae-Ro 119, Dong-Nam-Gu, Cheon-An-Si, Chung-Cheong-Nam-Do, 31116.

*** 정회원, Department of Applied Computer Engineering, College of Software Convergence, Dankook University, Juk-Jeon-Ro 152, Yong-In-Si, Kyung-Ki-Do, 16890.

© Corresponding Author(E-mail : drdwkim@dku.edu)

* This work was supported by the ICT R&D program of MSIT/IITP. [2018-0-00242, Development of AI ophthalmologic diagnosis and smart treatment platform based on big data].

Received ; June 28, 2019

Revised ; September 11, 2019

Accepted ; October 24, 2019

I. 서 론

당뇨병성 망막 병증은 당뇨병 환자의 대표적인 미세혈관 합병증으로서 우리나라에서 환자들에게 시력 저하 및 실명을 일으키는 주요한 원인 중 하나이며, 당뇨 환자의 약 60%가 이 질병이 발생한다^[1]. 안저 검사를 통해 빠른 치료가 이루어질수록 유병률이 낮아짐에도 불구하고 초기 단계에서는 환자가 인지할 수 있는 증상이 없기 때문에 발견 및 치료가 늦어지는 경향을 보인다^[2-3]. 당뇨병성 망막 병증의 초기 단계인 비증식성 당뇨병성 망막 병증의 경우 안저 검사를 통해 미세혈관류(Microaneurysm), 경성 삼출물(Hard exudate), 면화반(Soft exudate), 망막 출혈 등의 병리 증상을 관찰 할 수 있다. 미세혈관류는 당뇨병성 망막 병증에서 가장 먼저 관찰 할 수 있는 임상 소견으로서, 당뇨병성 망막 병증이 진행함에 따라 비정상적으로 확장되며 심할 경우 증식성 당뇨병성 망막 병증으로 발전 할 수 있다^[4]. 망막 출혈의 경우, 망막에 있는 혈관이 터져 시야가 흐려지거나 시력이 떨어지는 증상이 있다. 이때 경성 삼출물의 경우 망막혈관으로부터 장액이 새어 나와 지질이 남게 되는 현상으로, 경성 삼출물을 통해 환자의 혈중 콜레스테롤 수치를 추정 할 수 있다. Early Treatment Diabetic Retinopathy Study (ETDRS)^[5]에서는 당뇨병성 망막 병증을 증식성(PDR)과 비증식성(NPDR)으로 분류하고 비증식성을 정상 망막(No apparent retinopathy), 가벼운 비증식성 당뇨병성 망막 병증(Mild NPDR), 중증도 비증식성 당뇨병성 망막 병증(Moderate NPDR), 심한 비증식성 당뇨병성 망막 병증(Severe NPDR), 증식성 당뇨병성 망막 병증 (PDR)으로 세분화하였다. 이러한 분류를 통해 안과에서는 등급에 따라 다른 치료가 이루어지고 있으며 각각의 치료 방법^[6]이 다르기 때문에 환자의 망막 상태의 심각도 등급을 분류할 필요가 있다. 하지만 안저 영상을 관독하고 분류할 때 검사자의 주관적 해석이 개입될 수 있고 안저 촬영 장치에 따라 밝기, 명암, 색조 등이 다를 수 있으며 전문의가 아닌 경우 오진의 가능성이 존재한다. 따라서 당뇨병성 망막병증의 조기진단 및 분류를 위한 특이도와 민감도를 개선하기 위한 연구의 필요성이 대두되고 있다.

본 논문에서는 안저 영상으로부터 비증식성 당뇨병성 망막 병증의 초기 단계의 특징인 미세혈관류와 망막 출혈, 경성삼출물을 Faster R-CNN^[7]을 이용하여 검출하고 당뇨병성 망막 병증의 병리적 특징을 분석하여 안저 상태를 분류기를 이용하여 즉각적으로 진단하는 연구를

진행하였다. 제안하는 시스템의 당뇨병성 망막 병증 진단 및 분류는 크게 두 가지의 단계를 거쳐 이루어진다. 이는 당뇨병성 망막 병증의 병리적 특징을 검출하는 검출 단계와 분류기를 이용하여 병리적 특징을 분석하여 분류 및 진단을 하는 단계이다. Faster R-CNN을 이용한 검출 단계에서는 안저 촬영 장치에 구애 받지 않고 당뇨병성 망막 병증의 병리적 특징 영역을 검출해 낼 수 있도록 설계하였다. 분류기를 이용한 진단 및 분류 단계에서는 당뇨병성 망막 병증의 각 특징에 대한 정보를 분석하여 그 심각도 등급을 분류하도록 설계하였고, 주관적 해석 개입을 방지하고 객관적인 신뢰도와 민감도를 개선할 수 있도록 구성하였다. 본 연구를 통해 제안하는 분류기는 미세혈관류와 망막출혈 등의 병리 증상이 망막 내에서 차지하는 비율을 분석하여 심각도를 분류하는 방법과 랜덤포레스트^[8] 분류기를 이용하여 분류하는 방법으로 설계되었다. 본 논문의 구성은 2장에서 기존에 연구되었던 당뇨병성 망막 병증의 특징을 검출한 방법과 당뇨병성 망막 병증의 등급을 분류하기 위한 관련 연구에 대하여 소개하고, 3장에서 제안하는 시스템의 Faster R-CNN을 이용한 비증식성 당뇨병성 망막 병증의 병리 증상을 심각도 등급을 분류하는 방법에 대하여 설명한다. 4장에서는 실험 내용과 결과를 제시하고 성능을 평가, 분석하며 5장에서 결론을 맺는다.

II. 관련 연구

당뇨병성 망막 병증을 탐지하고 분류하기 위해 많은 연구가 이루어지고 있으며, 이러한 병리 증상을 검출하고 분류하는 의료 영상처리 기술과^[9-11] 머신러닝 기술이 다양하게 활용되고 있다. 대표적으로 Support Vector Machine (SVM)^[12]과 빅데이터를 기반으로 한 딥러닝 인공지능 기술인 Convolutional Neural Networks (CNN)을 활용한 의료영상 분석 방법^[13-14] 등의 연구가 다양하게 진행되고 있다^[15]. 딥러닝을 이용한 의료 영상 분석 방식은 학습 데이터에 의존적 특징을 가지나 다양한 환경 변화와 데이터의 변형과 같은 특징에 유연하다는 장점이 있다. 또한 빅데이터와 Graphic Processing Unit (GPU)를 활용한 빠른 연산 덕분에 딥러닝 기술은 지속적으로 발전하고 있으며, 최근 구글에서도 딥러닝을 기반으로 한 당뇨병성 망막 병증에 관한 연구를 진행한 바 있다^[16]. 영상처리 기법을 이용한 기존 연구의 경우, 당뇨병성 망막 병증에서 확인 할 수 있는 특징인 미세혈관류와 망막출혈을 세부적으로 분석하였다. 영상의

픽셀에서 병변과 다른 망막 특징은 녹색 채널 구성 요소에서 다른 색 영상과는 대조적으로 보이기 때문에^[17] 이미지 사이즈를 변환하고 붉은 병변을 식별해 내기 위한 전처리 작업을 거친다. 붉은 병변을 검출하고 분석하는 데에는 효율적으로 사용될 수 있으나, 당뇨병성 망막 병증의 심각도 등급을 분류하기에는 다양한 상황과 데이터의 형태 및 변형과 같은 밝기, 명암, 색조 등에 따라 오진의 가능성이 있다는 문제점이 있다. 한편, CNN 기법은 인간의 시신경 구조를 모방한 기술로 의료 영상 분석 및 해석에 필요한 특징을 자동으로 학습하는 기능을 가지고 있다. 최근 CNN을 이용하여 당뇨병성 망막 병증의 등급을 분류하는 연구가 활발히 진행되고 있다. Harry^[12] 등은 Kaggle^[18]에서 제공하는 6M 픽셀 80,000개 이상의 영상을 사용하였으며, 데이터 셋을 학습시키고 메모리의 손실을 줄이기 위해 영상의 크기를 512x512의 크기로 변경하여 진행하였다. Harry의 연구결과, 높은 특이도를 갖는 결과는 당뇨병성 망막 병증과 같이 초기에 정확한 진단을 받아야 빠른 치료가 이루어지는 질환에 유리하다. 그러나 낮은 민감도는 환자의 당뇨병성 망막 병증 유무를 알 수 있었을 뿐, 해당 병증의 등급 분류에는 많은 어려움이 있었다. 이는 당뇨병성 망막 병증에서 나타나는 특징인 미세혈관류와 망막출혈 등의 병리적 특성을 분석한 방식이 아니기 때문에 망막의 상태, 질병의 심각도를 정확히 분류하는 데에는 어려움이 존재한다. 당뇨병성 망막 병증의 진단 및 분류를 위한 연구는 지속적으로 진행되고 있으며, 특히 자동 분류를 위한 시스템 개발에 많은 연구 및 투자가 있어야 할 것으로 보인다.

III. Faster R-CNN과 랜덤포레스트를 이용한 당뇨병성 망막 병증 진단

본 연구에서는 Faster R-CNN과 랜덤포레스트 기법을 이용하여 안저 영상을 촬영하는 장비에 유연하고 밝기, 명암, 색조 등에 구애받지 않으면서도 당뇨병성 망막 병증의 병리적 특징을 빠르게 검출하고 심각도에 따른 등급을 분류하는 시스템을 고안하였다. 제안하는 시스템은 2단계로 구성되어 있다. 첫 번째 단계는 Faster R-CNN을 이용하여 당뇨병성 망막 병증의 특징을 검출하는 단계로서 학습한 특징인 미세혈관류와 망막출혈, 경성 삼출물의 병리적 특성을 인지하는 단계이다. 두 번째 단계에서는 Faster R-CNN으로 검출한 당뇨병성 망막 병증의 특징 데이터를 전처리 과정을 거친 후, 랜덤포

레스트 분류기를 이용하여 망막의 상태를 당뇨병성 망막 병증에 대해 진단하고, 심각도 등급을 분류하는 역할을 한다. 그림 1에 당뇨병성 망막 병증 검출 및 자동 분류 시스템의 전체적인 구조가 보이고 있다.




그림 1. Faster R-CNN과 랜덤포레스트 분류기를 이용한 당뇨병성 망막 병증 진단 시스템 구조

Fig. 1. Structure of Diabetic Retinopathy diagnosis classification system using Faster R-CNN and Random Forest methods.

1. Faster R-CNN을 이용한 당뇨병성 망막병증 특징 검출

Faster R-CNN의 원리는 CNN의 객체 검출 기법과 RPN (Region Proposal Network)을 사용하여 객체가 존재할 영역에 대한 목표 영역을 생성하여 학습하는 것이다. RPN을 이용하여 생성된 참조 영역들은 피라미드 형식으로 구성되고 Single-scale Image를 사용하여 학습 및 평가가 이루어짐으로써 검증 및 평가의 속도가 기존의 Fast R-CNN^[19]보다 다소 향상되었다. 먼저 당뇨병성 망막 병증의 특징 검출을 위해 Labeling 작업을 수행한다. 미세혈관류와 망막출혈은 Label 0, 경성 삼출물은 Label 1로 분류한다. 학습에 사용되는 데이터로는, 안저영상 내 증상들의 Box 좌표와 사전에 학습된 네트워크가 필요하다. 학습을 위한 당뇨병성 망막 병증의 자료는 XML 파일의 형태로서, 영상 파일의 경로와 영상의 전체 크기 그리고 학습하고자하는 객체의 이름과 좌표 (X_{max} , Y_{max} , X_{min} , Y_{min}), 4개의 변수로 구성되어 있다. 미세혈관류와 망막출혈 그리고 경성 삼출물의 예를 보이는 영상이 그림 2에 나타나있다. 사전 학습 네트워크 모델은 Inception ResNet v2^[20]를 사용하였으며 이 모델은 CNN의 컨볼루션 진행 단계에서 여러 개의 레이어를 구성한 형태로서, 복잡한 컨볼루션의 연산량을 줄이고 정확도를 높일 수 있는 장점이 있다. 그 후, Faster R-CNN을 당뇨병성 망막 병증의 병리 증상 검출에 사용하기 위해 학습 절차를 진행한다. Mini-batch 크기 16개에 대하여 랜덤하게 Anchor를 생성하고 반복




그림 2. 당뇨병성 망막 병증의 병리 증상 예시 (a) 미세 혈관류, (b) 망막출혈, (c) 경성삼출물

Fig. 2. Retinal lesions associated with diabetic retinopathy (a) Microaneurysms, (b) Retinal Hemorrhage, (c) Hard Exudate.

횟수만큼 RPN을 학습하였다.

RPN의 학습으로 생성된 목표 영역을 기반으로 하여 사전 학습된 네트워크와 학습 구조인 Inception Resnet v2를 이용하여 반복 횟수만큼 Faster R-CNN을 학습한다. 다시 학습된 Faster R-CNN을 기반으로 컨볼루션 계층의 학습 데이터를 공유하고 RPN을 반복 횟수만큼 학습한다. 공유한 컨볼루션 계층에 대하여 객체를 검출하기 유리한 방향으로 미세 조정을 거쳐 학습이 완료된다. Faster R-CNN을 이용한 당뇨병성 망막 병증의 병리 증상 검출 기법은 사전 학습된 모델로부터 Feature Map을 추출한 후, 이를 RPN과 RoI Pooling Layer로 넘겨준다. RoI Pooling Layer에서는 검출된 객체에 대한 Class Scores와 Box 좌표가 결과로 산출된다.

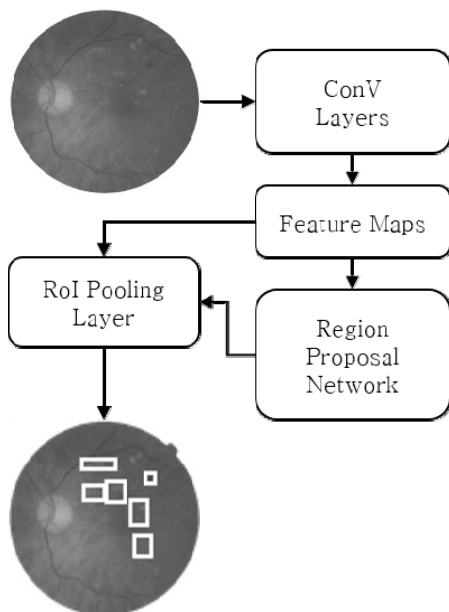


그림 3. 당뇨병성 망막병증 병리 증상 검출에 사용된 Faster R-CNN 구조

Fig. 3. Structure of Faster R-CNN for Detection of diabetic retinopathy pathology.

당뇨성 망막 병증의 특징을 검출에 사용된 Faster R-CNN 구조와 절차가 그림 3에 나타나 있다. 그림 4는 당뇨병성 망막 병증에 걸린 환자의 안저 사진을 입력 영상으로 하여 학습된 Faster R-CNN으로부터 얻어낸 결과로 학습한 병리 증상을 검출하여 원본 안저 영상에 병리 증상이 검출된 부분의 좌표에 흰색 박스를 삽입하여 만든 영상이다.




그림 4. Faster R-CNN을 이용한 병리증상 검출

Fig. 4. Detection of pathology from fundus image using Faster R-CNN method.

Faster R-CNN으로부터 산출된 결과는 해당하는 영역의 좌표를 토대로 해당 영역의 Pixel Value와 Labeling 작업을 통하여 이루어진 Class Type, 그리고 해당 클래스에 속할 확률인 Class Scores로 구성되어 있다. 각각의 결과값은 데이터 정제 및 전처리 과정을 거쳐 분류기로 전달된다. 표 1에 Faster R-CNN을 활용하여 안저 영상으로부터 산출해낸 정보목록이 나타나 있다.

표 1. Faster R-CNN을 이용해 추출된 특징정보 목록
Table 1. List of features extracted using Faster R-CNN.

1	Location point
2	Location Pixel Value
3	Class Type
4	Class Scores

2. 특징 정보 신호처리 과정

입력 영상인 안저 이미지로부터 당뇨병성 망막 병증의 특징인 미세혈관류, 망막 출혈, 경성 삼출물을 검출해내고 해당 특징 정보를 랜덤포레스트 단계로 전달하기 위해 데이터를 정제하고 전처리 과정을 거친다. 미세혈관류와 망막 출혈의 경우 Box로 이루어지는 직사각형 영역 내에서 모든 픽셀에 대하여 배경 영역과 구분하기 위해 해당 객체에 대한 픽셀 값을 256단계의 명암값으로

로 표현할 수 있도록 식 (1)과 같이 회색조로 변환한다. 그 뒤 각 영역의 픽셀을 식 (2)를 이용하여 역변환 한 후, 식 (3)의 히스토그램 평활화 과정을 적용한다. 이렇게 하여 명암 값의 분포를 균일하게 만들고 경계를 뚜렷하게 구분한 후, 배경 영역과 미세혈관, 망막출혈 영역을 분리할 수 있도록 한다. 다음 식 (4)와 같이 기본적인 임계처리 방식을 이용하여 이진영상의 바이너리 데이터로 픽셀을 추출하여 출혈 영역의 픽셀 개수를 도출한다.

$$g = (0.2126 \times R) + (0.7152 \times G) + (0.0722 \times B) \quad (1)$$

$$x' = |(255 - x)| \quad (2)$$

$$h(v) = R \left(\frac{cdf(v) - cdf_{\min}}{(M \times N) - cdf_{\min}} \times (L - 1) \right) \quad (3)$$

$$b(j, i) = \begin{cases} 1, & f(j, i) \geq T \\ 0, & f(j, i) < T \end{cases} \quad (4)$$

그림 5는 검출된 병리 증상으로부터 시작된 전체적인 전처리과정의 변화를 보여준다.




그림 5. 검출 정보 신호처리 과정 (a) 망막출혈 원본, (b) 회색조 변환, (c) 히스토그램 평활화, (d) 바이너리 이진 영상

Fig. 5. Signal processing of detected informations (a) Original hemorrhage, (b) Grayscale transformation, (c) Histogram equalization, (d) Binarized image.

안저 영상 내에서 망막 출혈과 미세혈관류의 분포를 분석하기 위하여 추출한 객체의 Box를 기준으로 X, Y 축의 좌표를 도출하여 각 객체간 거리의 합을 식 (5)와 같이 계산한다. 이 경우, 검출된 객체가 한 개 이하인 경우에는 1로 표시한다.

$$\overline{D} = \sum_{n=2}^N \sqrt{(X_n - X_{n-1})^2 + (Y_n - Y_{n-1})^2} \quad (5)$$

표 2는 전처리 과정을 거쳐 분류기로 전달되는 특징 정보이며, 당뇨병 망막 병증의 심각도를 분류하기 위해 사용되는 데이터이다.

표 2. 신호처리 후 분류기로 전달하는 데이터
Table2. Data transferred to classifier after signal processing.

1	미세혈관류 및 망막 출혈의 픽셀 개수
2	각 객체의 최대거리
3	Class Type
4	Class Scores

3. 당뇨병 망막 병증 진단 및 분류 시스템

ETDRS에서 분류한 당뇨병 망막 병증은 그림 6과 같이 등급이 세분화 되어있다. 임상적으로 미세혈관류가 관찰된 경우 가벼운 NPDR로 분류되고, 심한 NPDR은 염주 정맥이나 IRMA (Intraretinal microvascular abnormalities) 증상과 망막출혈, 미세혈관류가 4개 영역에 걸쳐 있을 경우이며, 중증도 NPDR의 경우 위 두 가지가 아닌 경우로 나뉘어진다. 본 연구를 통해 제안하는 분류 시스템에서는 비증식성 당뇨병 망막병증 중 가벼운 비증식성 당뇨병 망막 병증과 중간정도와 심한 정도의 비증식성 당뇨병 망막병증이 혼합된 등급으로 분류하도록 설계하였다.

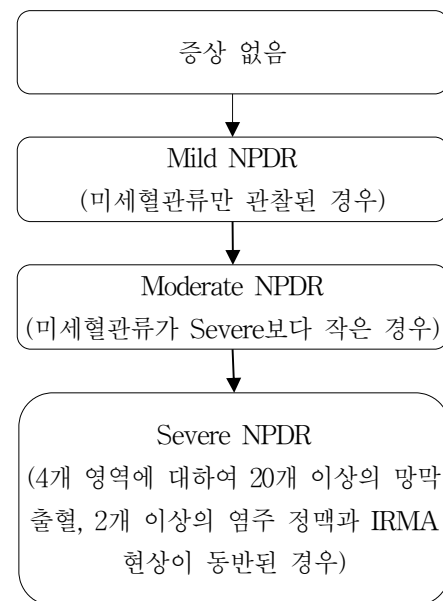


그림 6. 당뇨병 망막 병증 분류 (ETDRS)
Fig. 6. Classification of diabetic retinopathy (ETDRS).

가. 병리 증상의 영역을 이용한 등급 분류 방법

ETDRS의 당뇨병 망막 병증 분류 기준을 이용하여 입력된 안저 영상에 대해 전체 망막 내 미세혈관과 망막출혈, 경성 삼출물이 차지하는 영역의 비율을 분석하여 심각도의 등급을 분류하였다. 먼저 병리증상 영역의 면적을 계산하기 위해 입력 안저 영상에서 배경 영역을

제거한다. 그림 7은 배경영역을 제거한 안저 영상 이미지이다.




그림 7. 안저 영상에서 배경영역을 제거한 이미지 (a) 배경 제거 전, (b) 배경 제거 후

Fig. 7. Image with removed backgrounds from fundus image (a) before the removal of backgrounds, (b) after the removal of backgrounds.

그리고 Faster R-CNN을 이용하여 전달 받은 정보들 토대로 검출된 미세혈관과 망막출혈 (A), 경성삼출물 (B)의 픽셀 정보를 이용하여 전체 안저영역 (C)의 망막 내에서 차지하는 비율을 식 (6)을 이용하여 계산한다.

$$\alpha = (A + B) / C \quad (6)$$

망막 내에서 차지하는 비율 α 에 대하여 0.258보다 낮은 경우 가벼운 등급으로 분류하였고, 이보다 큰 경우에는 중간등급과 상태가 심한등급이 혼합된 등급으로 분류하여 결과를 출력하였다.

표 3. 병리증상이 전체 영역에서 차지하는 비율을 이용한 당뇨병성 망막 병증 등급 분류 기준

Table3. Diabetic retinopathy severity classification criteria using the ratio of pathology from the fundus images.

기준	분포도
정상	0
Mild (가벼운 정도)	0 ~ 0.258
Moderate (중간정도) or Severe (심한정도)	0.258 이상

여기서 α 값은 당뇨병성 망막병증 전문의에 의해 중증도 등급에 대한 판단이 완료된 안저 사진 58개를 활용하여 심각도 등급에 따른 병리 증상이 차지하는 비율의 분포를 분석한 후 도출한 결과로서 가벼운 등급과 중간 그리고 상태가 심한정도의 두 등급이 혼합된 등급을 분류하는 기준을 뜻한다. 표 3에 병리 증상이 차지하는 비율로 등급을 분류하는 기준이 나타나 있다. 입

력 영상으로부터 병리 증상을 검출하고 망막 내에서 차지하는 비율을 계산하여 당뇨병성 망막 병증의 심각도 등급을 분류하는 방법을 설명하는 전체적인 알고리즘이 그림 8에 나타나 있다.

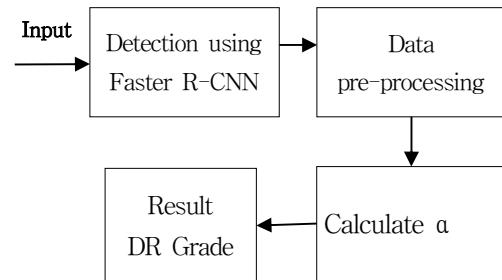


그림 8. 망막 영역 내 병리증상이 차지하는 비율을 통한 심각도 등급 분류 방법

Fig. 8. Diabetic retinopathy severity classification process through the ratio of pathology from fundus images.

나. 랜덤포레스트 기법을 이용한 당뇨병성 망막 병증 진단 및 분류

다음 단계의 분류 작업을 위해 머신 러닝의 대표적인 알고리즘 중 하나인 지도학습 (Supervised learning) 기반의 랜덤 포레스트 (Random forest) 기계학습 (Machine learning) 방법을 사용하여 연구를 진행하였다.

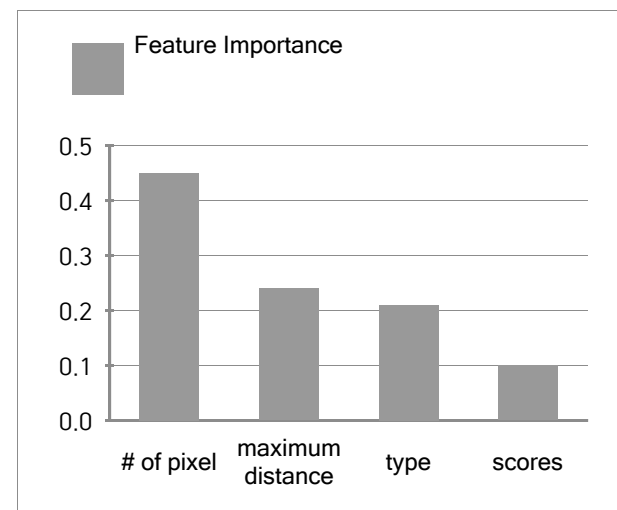


그림 9. 랜덤포레스트 분류학습에 대한 데이터 특성 중요도

Fig. 9. Feature Importance for Random forest classifier.

일반적인 결정 트리의 과대적합 (Over-fitting)과 일반화 (Under-fitting) 현상을 피할 수 있도록 설계된 랜덤 포레스트 알고리즘에서는 데이터집합에서 각 특징의

일부 변수를 무작위로 추출하여 결정 트리를 학습한 후 분류기를 생성하여 여러 개의 모델을 결합한 앙상블 학습 방법을 사용하였다. 랜덤 포레스트를 구성하는 의사 결정 트리의 집합에서 각각의 트리가 얻어낸 정보 획득량의 평균을 비교하여 데이터의 중요도를 분석한 결과가 그림 9에 나타나 있다. Faster R-CNN과 랜덤 포레스트 기법을 이용한 당뇨성 망막 병증 등급 분류 방법을 설명하는 순서도가 그림 10에 나타나있다.

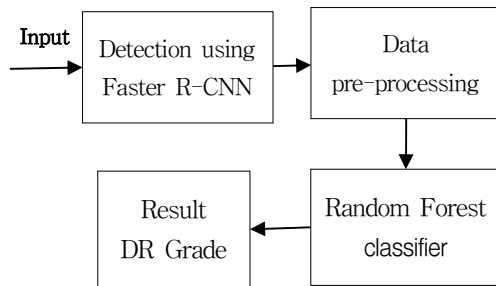


그림 10. 랜덤포레스트 기법을 이용한 당뇨병성 망막병증 등급 분류 방법

Fig. 10. Diabetic retinopathy severity classification process using Random forest classifier.

그림 10의 전체적인 순서는 Faster R-CNN을 활용한 당뇨성 망막 병증의 병리증상 검출과 랜덤포레스트를 활용한 당뇨성 망막 병증의 심각도 등급을 분류하는 과정으로 구성되어 있다. 입력된 안저 영상에 Faster R-CNN 기법을 적용하여 병리증상에 대한 확률과 해당 영역을 나타내는 Box의 좌표를 구한다. 그 후 데이터 신호처리 과정을 거쳐 Box 영역에 포함되어 있는 정확한 출력의 픽셀 개수와 병리 증상이 분포하고 있는 각각의 거리 값에 대한 데이터를 랜덤 포레스트 분류기로 전달한다. 그 다음 분류기는 정제 받은 데이터를 분석하여 당뇨성 망막병증의 중증도를 판단하는 심각도 등급을 분류한다.

IV. 실험 및 결과

1. 실험 환경

실험은 Windwos 10 운영체제에 설치한 Tesnor Flow의 Caffe 환경에서 Cuda 7.5를 사용하였으며 데이터 전처리에 해당하는 신호처리를 위해 OpenCV 3.0을 사용하였다. 실험환경은 표 4에 나타난 하드웨어 구성을 바탕으로 하였다.

표 4. 실험 진행에 갖추어진 환경

Table4. Experimental environments.

CPU	Intel I7-8700k @ 3.70Ghz
RAM	32Gb
GPU	NVIDIA GeForce GTX 1080
OS	Windows 10 Education
Tools	Caffe, cuda 7.5, OpenCV 3.0

2. Data Set

본 연구를 통해 제안하는 알고리즘의 학습과 평가에 사용된 자료는 *MESSIDOR* 데이터셋^[21] 과 단국대학교 의과대학병원에서 제공하는 안저 영상이다. *MESSIDOR* 데이터셋에서는 심각도에 대한 등급이 분류되어 있는 1200장의 안저 영상 자료를 사용하였고, 단국대병원에서 제공받은 데이터에서는 안과 전문의에 의해 심각도 등급이 분류된 103장의 안저 영상 데이터를 사용하였다. 그림 11에 *MESSIDOR*와 단국대병원의 Data set의 샘플 영상이 나타나 있다.




그림 11. 학습과 평가에 사용된 안저 영상 데이터 (a) *MESSIDOR* 안저 영상 데이터, (b) 단국대병원 제공 안저 영상 데이터

Fig. 11. Fundus images used for training and testing (a) *MESSIDOR* Fundus images, (b) Dankook University Hospital Fundus Images.

데이터는 당뇨성 망막 병증의 심각도 등급에 따라 표 5와 같이 분류하였다.

표 5. 실험에 사용된 안저 영상 데이터 분류

Table5. Categorization of Fundus image data used in the experiment.

Data sets		Training	Testing	Total
		<i>MESSIDOR</i>	DKU	
No. of images		653	103	756
Grade	mild	153	25	178
	moderate	247	29	276
	severe	253	49	302

MESSIDOR 데이터는 Mild 153장, Moderate 247장, Severe 253장이 사용되었으며, Faster R-CNN의 학습 데이터로 활용되었다. 학습데이터로 사용된 미세혈관류는 767개, 망막출혈은 649개, 경성 삼출물은 344개이며 총 1760개의 데이터가 학습에 이용되었다. 분류 시스템의 평가를 위해 단국대병원에서 제공받은 데이터, Mild 25장, Moderate 29장, Severe 49장 총 103장의 데이터를 사용하였다.

3. 분류 시스템을 이용한 실험

모든 실험은 동일한 데이터 셋을 이용해 Faster R-CNN의 Inception Resnet v2 모델을 사용하였으며, 당뇨병성 망막 병증 특징 추출 실험과 심각도를 분류하는 알고리즘의 성능 실험을 수행하였다. 분류 알고리즘으로는 병리 증상의 면적 비율을 이용한 분류 방법과 랜덤 포레스트 분류기를 사용하였다. 본 연구를 통해 제안하는 방법의 성능 검증을 위한 비교군으로 Harry 등의 CNN 모델과^[22] SVM (Support Vector Machine)을^[23] 활용하였다. 평가를 위해 TP (True Positive)는 가벼운 등급의 안저 영상을 가벼운 등급으로 분류하였을 경우, TN (True Negative)는 중간정도 또는 심한 등급을 중간정도 또는 심한 등급으로 분류하였을 경우, FP (False Positive)는 중간정도 또는 심한 등급을 가벼운 등급으로 분류하였을 경우, FN (False Negative)는 가벼운 등급을 중간정도 또는 심한 등급으로 평가하였을 경우로 사전에 정의하였고, Sensitivity, Specificity, Accuracy를 각각 식 (7), (8), 그리고 (9)과 같이 정의하여 분류 결과를 분석하고 평가하는데 사용하였다.

$$Sensitivity = \frac{TP}{TP + FN} \times 100 \quad (7)$$

$$Specificity = \frac{TN}{TN + FP} \times 100 \quad (8)$$

$$Accuracy = \frac{TP + TN}{(TP + FP + TN + FN)} \times 100 \quad (9)$$

본 연구를 통해 제안하는 분류 알고리즘에 대한 Test, 즉 평가는 단국대병원 측이 제공한 데이터 셋 103장을 이용하였고, 이를 통해 당뇨병성 망막 병증의 병리 증상을 탐지 및 검출하고 그 심각도 등급을 분류하였다.

가. 망막 내 병리 증상 영역 비율을 통한 분류 실험
이 실험에서는 당뇨병성 망막 병증의 병리 증상을 검출해 내고 해당 병리증상이 망막 내에서 차지하는 영역의 비

율을 토대로 심각도 등급을 분류하였다. 당뇨병성 망막 병증의 중증도 등급의 안저 영상을 Faster R-CNN을 이용하여 병리 증상 검출한 결과가 그림 12에 나타나 있다. 그 후 각 경성삼출물과 출혈에 대한 면적을 결과로 나타냈다.

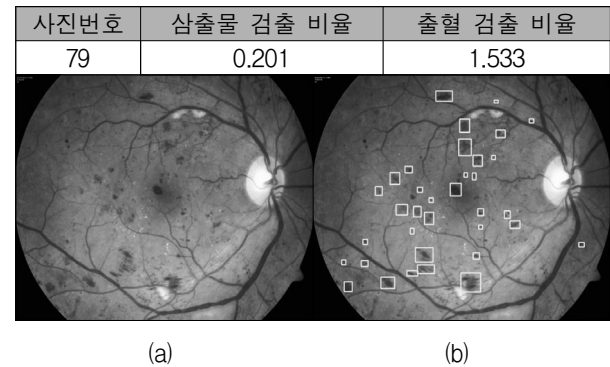


그림 12. Faster R-CNN 기법을 이용한 병리 증상 검출
(a) 입력 원본 이미지, (b) 검출결과 이미지

Fig. 12. Detection of pathology using Faster R-CNN method (a) original input image, (b) detection result image.

표 6은 103장의 안저 영상에서 검출된 병리증상의 비율을 나타내며 안저 등급과 병리증상이 차지하는 비율의 상관관계를 확인 할 수 있다. 당뇨병성 망막 병증의 초기단계일수록 삼출물과 출혈의 비율이 상대적으로 적으며 질병이 악화될수록 출혈과 삼출물의 비율이 늘어나는 것을 확인 할 수 있다.

표 6. Faster R-CNN을 이용한 병리 증상 검출 결과
Table 6. Result of pathology detection using Faster R-CNN method.

파일명	삼출물 비율(%)	출혈 비율(%)	합 계(%)
001.jpg	0	0	0
009.jpg	0	0	0
006.jpg	0.017	0	0.017
008.jpg	0.026	0	0.026
016.jpg	0.026	0	0.026
004.jpg	0.034	0	0.034
005.jpg	0.041	0	0.041
072.jpg	0	0.052	0.052
002.jpg	0.058	0	0.058
114.jpg	0.080	0	0.080
046.jpg	0	0.083	0.083
027.jpg	0.055	0.030	0.086
011.jpg	0.104	0	0.104
029.jpg	0.106	0	0.106
007.jpg	0.184	0	0.184
035.jpg	0.038	0.168	0.206

071.jpg	0.022	0.193	0.215
092.jpg	0.094	0.152	0.246
070.jpg	0.005	0.258	0.263
085.jpg	0.140	0.147	0.287
087.jpg	0.166	0.121	0.287
038.jpg	0	0.319	0.319
088.jpg	0.126	0.193	0.319
048.jpg	0	0.382	0.382
056.jpg	0.265	0.123	0.389
083.jpg	0.216	0.193	0.409
094.jpg	0.417	0	0.417
028.jpg	0.357	0.072	0.429
025.jpg	0.116	0.343	0.460
065.jpg	0.200	0.301	0.501
003.jpg	0.505	0	0.505
084.jpg	0.109	0.410	0.520
086.jpg	0.118	0.411	0.529
069.jpg	0.181	0.349	0.531
076.jpg	0.108	0.437	0.545
074.jpg	0.065	0.567	0.633
111.jpg	0.430	0.205	0.636
015.jpg	0	0.651	0.651
078.jpg	0.434	0.245	0.680
093.jpg	0.447	0.270	0.718
090.jpg	0.581	0.210	0.792
081.jpg	0.408	0.393	0.801
100.jpg	0.137	0.709	0.847
060.jpg	0.484	0.364	0.849
037.jpg	0	0.855	0.855
077.jpg	0.447	0.504	0.952
063.jpg	0.531	0.423	0.955
021.jpg	0.614	0.354	0.969
023.jpg	0.734	0.235	0.970
022.jpg	0.661	0.310	0.971
024.jpg	0.566	0.410	0.976
032.jpg	0.685	0.296	0.981
036.jpg	0.788	0.208	0.997
014.jpg	0.784	0.217	1.00
058.jpg	0.320	0.696	1.017
052.jpg	0.870	0.200	1.071
051.jpg	0.681	0.437	1.118
064.jpg	1.115	0.032	1.148
030.jpg	0.813	0.611	1.425
034.jpg	0.782	0.647	1.429
075.jpg	1.335	0.126	1.461
045.jpg	1.272	0.452	1.725
079.jpg	0.201	1.533	1.734
047.jpg	0.036	1.763	1.800
055.jpg	0.312	1.522	1.834
057.jpg	1.424	0.470	1.895
059.jpg	0.423	1.486	1.909
061.jpg	1.145	0.957	2.102
089.jpg	1.634	0.537	2.171
062.jpg	1.598	0.827	2.426
054.jpg	1.439	1.084	2.524

066.jpg	1.631	0.905	2.536
091.jpg	2.588	0	2.5 88
109.jpg	1.851	0.863	2.714
039.jpg	2.461	0.352	2.814
068.jpg	2.312	0.511	2.824
082.jpg	1.775	1.088	2.864
067.jpg	1.488	1.474	2.963
044.jpg	2.152	0.822	2.975
041.jpg	1.480	1.503	2.983
113.jpg	2.578	0.437	3.015
080.jpg	2.420	0.725	3.145
095.jpg	1.979	1.233	3.212
110.jpg	0.936	2.348	3.285
105.jpg	2.801	0.558	3.359
103.jpg	2.029	1.337	3.367
098.jpg	2.280	1.114	3.394
101.jpg	3.354	0.078	3.433
053.jpg	0.586	2.905	3.492
104.jpg	2.190	1.377	3.567
050.jpg	3.525	0.386	3.912
107.jpg	3.807	0.166	3.973
043.jpg	1.341	2.645	3.987
049.jpg	4.237	0.160	4.397
099.jpg	3.712	0.715	4.428
108.jpg	3.018	1.806	4.824
106.jpg	3.024	2.030	5.054
112.jpg	4.404	0.690	5.095
102.jpg	5.098	0.368	5.466
097.jpg	1.741	3.735	5.476
040.jpg	5.541	0	5.541
042.jpg	5.888	0	5.888
096.jpg	3.875	2.130	6.006

병리 증상이 차지하는 비율을 토대로 중증 심각도 등 급을 분류하였다. 분류결과를 Confusion Matrix에 대입하고 Sensitivity, Specificity, Accuracy를 각각 계산한 결과가 표 7에 나타나있다.

표 7. Confusion Matrix 및 평가지표를 이용한 분석 결과
Table7. Confusion Matrix and Evaluation Result.

분류 결과	TP	TN	FP	FN
	17	78	0	8
분석 결과	Sensitivity		Specificity	Accuracy
	68%		100%	92%

표 7에 나타난 바와 같이 True Negative의 경우 78개 중 78개를 분류해내어 정확한 결과를 얻을 수 있었지만 True Positive의 경우 데이터의 병리증상 비율을 이용한 방법으로는 분류해 낼 수 없는 안저 영상이 존재하여 분류에 어려움이 있었다. Accuracy는 92%로서 양호한 검출 결과를 도출하였다. 하지만 100%인

Specificity에 비해 68%라는 낮은 Sensitivity의 결과로 보아 안저 연상의 망막 병리증상에 해당하는 영역 비율만을 이용하여 당뇨병성 망막 병증의 등급을 분류하는 것에는 한계가 있음을 알 수 있다.

나. Random Forest 기법을 이용한 분류

이번 실험에서는 Faster R-CNN을 통하여 추출한 데이터들을 토대로 랜덤포레스트를 이용한 당뇨병성 망막 병증 중증도 등급 분류를 진행하였다. 먼저 Faster R-CNN을 이용하여 병리증상 데이터를 검출하였고 이는 그림 13에 예시되어 있다.




그림 13. Faster R-CNN을 통한 병리 증상 검출 결과
Fig. 13. Pathology detection result through Faster R-CNN.

Faster R-CNN으로 검출된 병리 증상의 영역과 붉은 병변을 추출하기 위하여 데이터 전처리 과정을 수행한다.



그림 14. 그림 13의 각각 이미지를 신호처리한 결과
Fig. 14. Result of signal processing for Fig. 13.

그림 14는 그림 13의 병리증상 이미지에 전처리를 수행한 결과 영상이다. 전처리 후 데이터는 출혈 병변의

픽셀과, 면적을 계산하기 위해 사용되며 Faster R-CNN으로부터 얻어진 각 객체의 최대거리와 Class, Scores를 랜덤포레스트 분류기로 전달한다. 앞서 획득한 데이터를 토대로 랜덤포레스트 분류기를 학습한다. 특징 데이터의 범위를 0에서 1사이의 값으로 조정하고 제한된 메모리 영역을 고려하여 의사 결정 트리의 개수와 깊이를 조정하며 과대적합을 줄여 안정적인 모델을 만들기 위해 성능 변화를 관찰하였다. 그림 15와 16은 의사 결정 트리의 개수와 깊이에 따른 성능 변화를 그래프로 나타내고 있다.

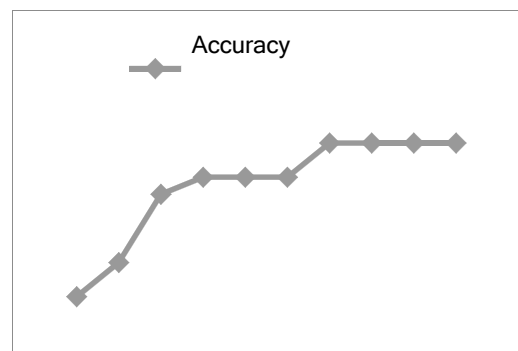


그림 15. 의사 결정 트리 개수에 따른 성능 변화
Fig. 15. Performance variation result with respect to the number of decision tree.

그림 15에 나타난 그래프에서 x축은 의사결정 트리의 수를 나타내며, 의사 결정 트리의 개수는 13개 이상부터 y축의 Accuracy가 1이 되고, 이 시점부터 랜덤포레스트 분류기가 과대적합 상태를 이루게 된다.




그림 16. 의사 결정 트리의 최대 깊이에 따른 성능 변화
Fig. 16. Performance variation result with respect to the maximum depth of decision tree.

또한 그림 16의 그래프에서 볼 수 있듯이 랜덤 포레스트 분류기는 의사결정 트리의 최대 깊이가 7 이상이 될 때 과대적합 상태가 되므로 학습을 위해 사용하는

의사결정 트리의 개수는 11개, 의사결정 트리의 최대 깊이는 6으로 설정하였으며 앞선 실험에서 사용한 것과 동일한, 단국대병원에서 제공한 103장의 데이터를 이용하여 랜덤포레스트 분류기를 테스트하였다. 표 8에 분류 결과를 정리한 Confusion Matrix가 나타나 있다.

표 8. Confusion Matrix 및 평가지표 결과
Table8. Confusion Matrix and Evaluation Result.

분류 결과	TP	TN	FP	FN
	24	78	0	1
분석 결과	Sensitivity	Specificity	Accuracy	
	96%	100%	99%	

표 8을 보면 TP와 TN으로 분류된 영상이 전체 103개의 테스트 이미지 중에 각각 24개와 78개였으며 앞선 실험인 망막 내 병리 증상 영역의 비율을 계산해 분류한 결과와 비교해 보면 8개였던 FN의 결과를 1개로 줄이는 성과를 보였다. 이를 통해 Faster R-CNN으로부터 검출된 데이터의 신호처리 과정 후 랜덤 포레스트 기법을 이용한 분류기 활용의 실험과정이 양호한 실험 결과를 도출해냈음을 알 수 있다.

다. 분류 방법 비교 평가

마지막 실험은 본 연구를 통해 제안한 Faster R-CNN으로부터 랜덤포레스트에 이르는 분류기의 성능을 평가하기 위해 SVM과 CNN을 비교 대상 알고리즘으로 지정하고 동일한 데이터 셋을 이용해 평가를 진행하였다. SVM의 Kernel은 Linear 모델을 대상으로 하여 실험을 진행하였고, 랜덤포레스트에서 사용되는 동일한 데이터 전처리과정을 수행한 후, 커널 사이즈를 조절하며 가장 높은 정확도를 갖는 모델을 대상으로 하여 평가하였다. CNN의 경우에는 앞에서 언급한 Harry 등의 네트워크 모델을 구현하여 비교하고 평가하였다. CNN의 학습데이터로는 *MESSIDOR* 데이터를 이용하였고 단국대병원의 데이터 103장에 대하여 실험을 진행하였다. 표 9에 본 연구에서 제안하는 방법과 SVM, CNN의 실험 결과를 비교분석한 내용이 제시되어있다. SVM을 이용한 분류 결과는 망막 내 병리증상 영역의 비율을 분석해 분류한 방법에 비해 FN을 분류함에 있어서 더 나은 성능을 보였고, 대신 FP로 4개의 영상을 분류하여 SVM 알고리즘의 성능 개량 또는 향상을 고려해야함을 보여주었다. TP와 TN은 제안한 방법과 비슷한 성능을 보여주었으나, 더 우월한 점은 보여주지 못했다.

표 9. 분류기의 비교평가를 위한 Confusion Matrix와 성능 평가지표 결과

Table9. Confusion matrix for performance comparison and evaluation of the classifier and result of analysis and evaluation.

	TP	TN	FP	FN
SVM	21	74	4	4
CNNs	6	78	0	19
Proposed	24	78	0	1

	Sensitivity	Specificity	Accuracy
SVM	84%	94.8%	92.2%
CNNs	24%	100%	80%
Proposed	96%	100%	99%

CNN을 이용한 분류 결과는 Specificity에서는 100%의 성능을 보여주었으나, Sensitivity에서 24%로 저조한 결과를 보여주었다. 이는 TP에서 19개의 오판단을 하였고 FN에서 무려 19개의 오류를 범해 평가 지표계산에 불리하게 기인한 것으로 보인다. 덧붙여, SVM을 통하여 분류에 실패한 가벼운 등급의 안저 영상을 살펴보면 중증도 등급에서 망막 출혈이 거의 일어나지 않은 환자의 안저 영상과 비슷한 정도의 망막 출혈이 있음을 확인 할 수 있었으며 이러한 데이터를 적절히 분류하지 못한 이유도 있는 것으로 판단된다. 성능 비교군으로 사용된 CNN은 앞서 언급한 당뇨병성 망막 병증의 병리적 특징을 분석한 방식이 아니기 때문에 중증도 등급의 안저 영상과 경미한 등급의 안저 영상을 분류하는 데에는 만족스럽지 못한 결과를 보였다. 향후 더 많은 양의 망막병증 병리현상을 보이는 안저 데이터를 확보하여 정상과 비정상인 안저 상태를 분류하는 알고리즘을 포함하여 중증도를 더 세밀하게 분류해내는 시스템을 구축할 수 있도록 연구를 진행할 예정이다.

V. 결 론

본 논문에서는 Faster R-CNN과 랜덤포레스트 기법을 활용하여 높은 분류 정확도를 갖는 당뇨병성 망막 병증 검출 및 심각도 등급 분류 시스템을 제안하였다. 병리증상과 당뇨병성 망막 병증의 심각도 등급사이의 상관관계에 대한 실험을 통해 효율적인 분류를 위한 데이터 전처리 과정이 필요하고 데이터의 특징과 머신러닝의 장점을 이용하여 분류기 시스템을 학습함으로써 적절한 분류 결과를 도출 할 수 있었다. 본 연구에 적용된 Faster R-CNN 알고리즘의 훈련은 상대적으로 적은 수

의 데이터를 학습에 활용하여 당뇨병 망막 병증의 병리 증상에 관한 데이터를 추출하였고, 향후 더 많은 데이터가 수집된다면, 향상된 결과를 도출할 수 있을 것으로 보인다. 또한 Tensor Flow Caffe Model을 활용하여 Faster R-CNN을 구현하고 랜덤포레스트 분류기를 이용하여 등급을 분류하는 기능을 추가함으로써 양호한 결과를 도출할 수 있었다. 본 연구를 통해 제안한 랜덤포레스트 분류기를 통한 분류 방법은 SVM과 CNN 등 기존의 분류 방법들과 함께 비교평가를 위해 분석되었고, 정확도 등을 포함한 성능 평가지표측면에서 타 기법들에 비해 우수한 결과를 도출함을 확인할 수 있었다. Training에 필요한 의미 있는 자료들을 다 수 확보한다면 중증도 및 심각한 정도의 등급을 분류해 내는데 많은 도움이 될 것으로 보인다. 향후 연구에서는 본 논문에서 제안하는 방법을 확장하여 안저 촬영 장치와 연동하여 실시간으로 분류하는 기능을 활용 가능하도록 하여 검사자의 빠르고 객관적인 판단을 유도하고, 자동으로 세부적인 심각도의 등급을 분류할 수 있는 시스템을 설계하고 개발하는 연구를 진행할 예정이다.

REFERENCES

- [1] C. W. Choi, S. J. Lee, H. R. Kang, and Y. S. Yang, "The change of microaneurysm in diabetic retinopathy patients who undergo intravitreal avastin (bevacizumab) injection," *Journal of Korean Ophthalmol Society*, Vol. 55, No. 10, pp. 1481-1486, June 2014.
- [2] Y. Park, "Management of the patient with diabetes mellitus and macro- and microvascular complications," *Journal of Korean Med Assoc*, Vol. 48, No. 8, pp. 721-734, August 2009.
- [3] R. E. Smith, and A. Patz, "Diabetes 2000 - Closing the gap (editorial)," *Ophthalmology*, Vol. 97, No. 2, pp. 153-154, February 1990.
- [4] J. H. Song, "Prevention and management of diabetic retinopathy," *Journal of Korean Medical Association*, Vol. 57, No. 6, pp. 525-534, June 2014.
- [5] The Early Treatment Diabetic Retinopathy Study Research Group, "ETDRS report No. 12: Fundus photographic risk factors for progression of diabetic retinopathy," *Ophthalmology*, Vol. 98, No. 3, pp. 823-833, May 1991.
- [6] A. Pai, E. M. M. Shafei, O. A. Z. Mohammed, and A. M. Hashimi, "Current concepts in intravitreal drug therapy for diabetic retinopathy," *Saudi Journal of Ophthalmology*, Vol. 24, No. 4, pp. 143-149, December 2010.
- [7] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," *Advances in Neural Information Processing Systems*, pp. 91-99, 2015.
- [8] L. Breiman, "Random forests," *Machine Learning*, Vol. 45, No. 1, pp. 5-32, 2001.
- [9] M. Niemeijer, B. V. Ginneken, J. Staal, M. S. Suttorp-Schulten and M. D. Abramoff, "Automatic detection of red lesions in digital color fundus photograph," *IEEE Transactions on Medical Imaging*, Vol. 24, No. 5, May 2005.
- [10] H. F. Jaafar, A. K. Nandi, and W. Al-Nuaimy, "Automated detection of red lesions from digital colour fundus photographs," *33rd Annual International Conference of IEEE Eng. Med. Biol. Soc.*, pp. 6232-6235, Boston, Massachusetts, August 2011.
- [11] J. J. Hwang, "Forensic Detection of Filtration Forgery in Digital Images," *Journal of the Institute of Electronics and Information Engineers*, Vol. 56, No. 1, pp. 85-91, 2019.
- [12] E. V. Carrera, A. González, and R. Carrera, "Automated detection of diabetic retinopathy using SVM," *IEEE XXIV International Conference on Electronics, Electrical Engineering and Computing*, pp. 1-4, August 2017.
- [13] H. Pratt, F. Coenen, D. M. Broadbent, S. P. Harding, and Y. Zheng, "Convolutional Neural Networks for Diabetic Retinopathy," *International Conference on Medical Imaging Understanding and Analysis*, Vol. 90, pp. 200-205, July 2016.
- [14] J. J. Sim, W. J. Jung, H. S. Yang, B. G. Han, Y. C. Cho and Y. S. Moon, "Nuclei Segmentation utilizing CNN and Guide image," *Journal of the Institute of Electronics and Information Engineers*, Vol. 55, No. 9, pp. 83-91, 2018.
- [15] G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, J. A. W. M. van der Laak, B. van Ginneken, and C. I. Sanchez, "A survey on deep learning in medical image analysis," *Medical Image Analysis*, Vol. 42, pp. 60-88, December 2017.
- [16] V. Gulshan, L. Peng, M. Coram, M. C. Stumpe, D. Wu, A. Narayanaswamy, S. Venugopalan, K. Widner, T. Madams, J. Cuadros, R. Kim, R. Raman, P. C. Nelson, J. L. Mega, D. R. and Webster, "Development and validation of a deep learning algorithm for detection of diabetic

- retinopathy in retinal fundus photographs,” Journal of Am. Medd. Assoc., Vol. 316, No. 22, pp. 2402-2410, 2016
- [17] T. Walter, J. C. Klein, P. Massin, “A contribution of image processing to the diagnosis of diabetic retinopathy detection of exudates in colour fundus images of the human retina,” IEEE Transactions on Medical Imaging, Vol. 21, No. 10, pp. 1236-1243, October 2002.
- [18] Kaggle Diabetic Retinopathy Detection competition, <https://www.kaggle.com/c/diabetic-retinopathy-detection>. Accessed June 30, 2016.
- [19] R. Girshick, “Fast R-CNN,” Proceedings of the IEEE International Conference on Computer Vision, pp. 1440-1448, 2015.
- [20] C. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi, “Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning,” AAAI, 2017.
- [21] E. Decencière, D. Etienne, and Z. Xiwei, et al., “Feedback on a publicly distributed image database: the Messidor database,” Image Anal Stereol. Vol. 33, No. 3, pp. 231-234, 2014.
- [22] E. K. Kim, “Extraction and Complement of Hexagonal Borders in Corneal Endothelial Cell Images,” Journal of The Institute of Electronics Engineers of Korea, Vol. 50, No. 3, pp. 102-112, March 2013.
- [23] H. J. Lee, “Fuzzy-based Segmentation Algorithm for Brain Images,” Journal of the Institute of Electronics Engineers of Korea, Vol. 46, No. 12, pp. 102-107, December 2008.

저 자 소 개



정 영 훈(학생회원)
2017년 단국대학교 멀티미디어
공학과 학사 졸업.
2019년 단국대학교 대학원
컴퓨터학과 석사과정

<주관심분야: 신호처리, 영상처리, 머신러닝, 딥러닝, Mask-R-CNN>



조 경 진(비회원)
2005년 단국대학교 의학과
학사 졸업
2010년 가톨릭대학교 의학과
안과학 석사
2014년 가톨릭대학교 의학과
안과학 박사

현재 단국대학교 의과대학 의학과 교수 (안과학)
<주관심분야: 녹내장, 백내장, 당뇨병망막병증, 각막괴양, 황반변성>



김 대 원(정회원) - 교신저자
1993년 중앙대학교 공과대학
전자공학과 학사 졸업.
1996년 University of Southern
California, Electrical and
Computer Engineering,
M.S.

2002년 Iowa State University, Electrical and
Computer Engineering, Ph.D.

현재 단국대학교 SW융합대학 응용컴퓨터공학과
교수

<주관심분야: Digital Multimedia Data
Processing, Non Destructive Evaluation, Source
Localization, Deep-learning, CNN>